Центральный университет
Научный трек

Сходимость представлений нейросетей разных архитектур, модальностей и задач на примере рекомендательных систем

Талменев Владимир Александрович

11 ноября 2026 г.

Тема и цель исследования

Исследуется сходимость представлений нейросетей разных архитектур, модальностей и задач на примере рекомендательных систем.

Основа — гипотеза платоновского представления [1]: с ростом масштаба модели разных архитектур и модальностей сходятся к общей статистической модели реальности. Гипотеза

- проверена только для зрения и текста [1, 6];
- зависит от размера выборки и калибровки мер сходства [2, 3];
- для рекомендательных моделей не проверялась.

Цель исследования —

выяснить, сходятся ли представления товаров у рекомендательных моделей между собой и с языковыми моделями и от каких факторов это зависит.

Обзор литературы

Группа работ	Достоинства	Ограничения
Склейка и отображения [8–11]	Прямо проверяют совместимость	Нужно обучать отображение
Соседи: зрение и язык [1, 6, 7]	Простая мера, растёт с масштабом	Зависит от выборки и k [2]
Меры и калибровка [3, 14–16]	Калибровка убирает завышение [3]	CKA неустойчива [16]
Теория [1, 5, 32, 33]	Объясняет сходимость к ядру PMI	Идеализированные допущения
Язык в рекомендациях [21–24]	Линейное отображение работает [24]	Мерят качество, а не геометрию
Сравнение рекомендателей [25, 31]	ID и текст дополняют друг друга [25]	Нет связи с гипотезой и масштабом

Основа работы — протокол [1], калиброванные меры [3] и линейное отображение [24]. Сходимость рекомендательных моделей с учётом критики мер не исследовалась.

Постановка задачи

Решается задача оценки сходимости представлений товаров у разных моделей.

Заданы

1) товары $\mathcal{I} = \{1, \dots, n\}$, взаимодействия $R \in \{0,1\}^{m \times n}$, описания товаров $t_1, \dots, t_n$;
2) рекомендательная модель $f_\theta \colon \mathcal{I} \to \mathbb{R}^d$ и языковая модель $g \colon t_i \mapsto g(t_i) \in \mathbb{R}^{d'}$ с матрицами представлений $F_\theta \in \mathbb{R}^{n \times d}$, $G \in \mathbb{R}^{n \times d'}$.

Внутренний критерий (ω — размер модели, объём данных, число задач, λ):

$$\theta^*(\omega) = \arg\min_\theta \mathcal{L}_{\text{rec}}(\theta; R_\omega) + \lambda \|\theta\|_2^2.$$

Сходство пространств — калиброванная доля общих k ближайших соседей:

$$m_k(F, G) = \frac{1}{nk} \sum_{i=1}^{n} \left| N_k^F(i) \cap N_k^G(i) \right|, \qquad \tilde{m}_k = m_k(F, G) - \mathbb{E}_\pi \, m_k(F, G_\pi).$$

Внешний критерий — Recall@K и NDCG@K на отложенном последнем товаре.

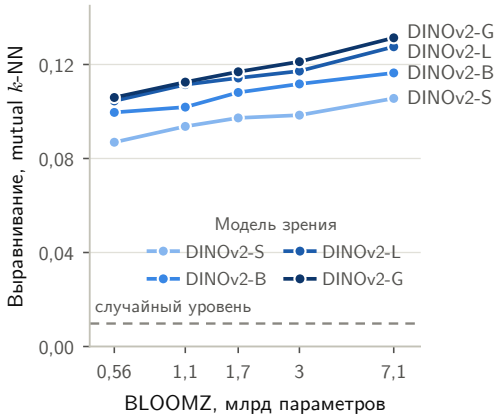
Требуется найти зависимость $\tilde{m}_k\big(F_{\theta^*(\omega)}, G\big)$ от ω и от NDCG@K; эталон — $K_{\text{PMI}}(i,j) = \log\big(P(i,j)/P(i)P(j)\big)$.

Базовый эксперимент: воспроизведение [1]

Цель эксперимента — проверить меру и протокол на данных основной статьи до перехода к рекомендательным моделям.

Данные	WIT-1024: 1024 пары «картинка — подпись» из Википедии [1]
Модели	языковые BLOOMZ от 0,56 до 7,1 млрд параметров; модели зрения DINOv2-S, -B, -L, -G
Мера	mutual k-NN, $k = 10$, максимум по парам слоёв; контроль — перемешанные пары
Ожидание	выше случайного уровня $k/(n-1) \approx 0{,}01$ и рост с размером модели [1]; для OpenLLaMA-3B и DINOv2-B получено 0,135 [2]

Результаты базового эксперимента



- выравнивание растёт с размером обеих моделей: от 0,087 до 0,131;
- лучшая пара BLOOMZ-7b1 и DINOv2-G — в 13 раз выше случайного уровня;
- на перемешанных парах — 0,0098, то есть случайный уровень;
- лучшие слои — в конце обеих сетей.

Порядок величины тот же, что в [2]; там же показано, что на больших выборках значение падает. Далее — рекомендательные модели на MovieLens.

Список литературы

[1] M. Huh, B. Cheung, T. Wang, and P. Isola, "Position: The Platonic Representation Hypothesis," in *Proceedings of the 41st International Conference on Machine Learning (ICML)*, ser. PMLR, vol. 235, 2024, pp. 20 617–20 642.

[2] A. S. Koepke, D. Zverev, S. Ginosar, and A. A. Efros, "Back into Plato's Cave: Examining Cross-modal Representational Convergence at Scale," arXiv:2604.18572, 2026.

[3] F. Gröger, S. Wen, and M. Brbić, "Revisiting the Platonic Representation Hypothesis: An Aristotelian View," arXiv:2602.14486, 2026.

[4] R. Jha, C. Zhang, V. Shmatikov, and J. X. Morris, "Harnessing the Universal Geometry of Embeddings," arXiv:2505.12540, 2025.

[5] R. Balestriero and Y. LeCun, "Proving and Improving the Platonic Representation Hypothesis with JEPAs," arXiv:2610.39302, 2026.

[6] M. Maniparambil *et al.*, "Do Vision and Language Encoders Represent the World Similarly?" in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024.

[7] P. Sharma *et al.*, "A Vision Check-up for Language Models," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024.

[8] J. Merullo, L. Castricato, C. Eickhoff, and E. Pavlick, "Linearly Mapping from Image to Text Space," in *International Conference on Learning Representations (ICLR)*, 2023.

Список литературы

[9] L. Moschella, V. Maiorca, M. Fumero, A. Norelli, F. Locatello, and E. Rodolà, "Relative Representations Enable Zero-Shot Latent Space Communication," in *International Conference on Learning Representations (ICLR)*, 2023.

[10] Y. Bansal, P. Nakkiran, and B. Barak, "Revisiting Model Stitching to Compare Neural Representations," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, 2021.

[11] A. Dravid, Y. Gandelsman, A. A. Efros, and A. Shocher, "Rosetta Neurons: Mining the Common Units in a Model Zoo," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023.

[12] S. K. Ainsworth, J. Hayase, and S. Srinivasa, "Git Re-Basin: Merging Models modulo Permutation Symmetries," in *International Conference on Learning Representations (ICLR)*, 2023.

[13] M. Abdou *et al.*, "Can Language Models Encode Perceptual Structure Without Grounding? A Case Study in Color," in *Proceedings of the 25th Conference on Computational Natural Language Learning (CoNLL)*, 2021.

[14] S. Kornblith, M. Norouzi, H. Lee, and G. Hinton, "Similarity of Neural Network Representations Revisited," in *Proceedings of the 36th International Conference on Machine Learning (ICML)*, ser. PMLR, vol. 97, 2019.

[15] M. Klabunde, T. Schumacher, M. Strohmaier, and F. Lemmerich, "Similarity of Neural Network Models: A Survey of Functional and Representational Measures," *ACM Computing Surveys*, vol. 57, no. 9, 2025, art. 242.

Список литературы

[16] M. Davari, S. Horoi, A. Natik, G. Lajoie, G. Wolf, and E. Belilovsky, "Reliability of CKA as a Similarity Measure in Deep Learning," in *International Conference on Learning Representations (ICLR)*, 2023.

[17] I. Sucholutsky, L. Muttenthaler *et al.*, "Getting Aligned on Representational Alignment," *Transactions on Machine Learning Research (TMLR)*, 2025, arXiv:2310.13018.

[18] W.-C. Kang and J. McAuley, "Self-Attentive Sequential Recommendation," in *IEEE International Conference on Data Mining (ICDM)*, 2018.

[19] F. Sun *et al.*, "BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer," in *Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM)*, 2019.

[20] X. Xie *et al.*, "Contrastive Learning for Sequential Recommendation," in *IEEE 38th International Conference on Data Engineering (ICDE)*, 2022.

[21] Y. Hou *et al.*, "Towards Universal Sequence Representation Learning for Recommender Systems," in *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)*, 2022.

[22] J. Li *et al.*, "Text Is All You Need: Learning Language Representations for Sequential Recommendation," in *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)*, 2023.

Список литературы

[23] Z. Yuan, F. Yuan, Y. Song, Y. Li, J. Fu, F. Yang, Y. Pan, and Y. Ni, "Where to Go Next for Recommender Systems? ID- vs. Modality-based Recommender Models Revisited," in *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR)*, 2023.

[24] L. Sheng, A. Zhang, Y. Zhang, Y. Chen, X. Wang, and T.-S. Chua, "Language Representations Can be What Recommenders Need: Findings and Potentials," in *International Conference on Learning Representations (ICLR)*, 2025.

[25] L. Collins, B. Kumar, C. M. Ju, T. Zhao, D. Loveland, L. Neves, and N. Shah, "Exploiting ID-Text Complementarity via Ensembling for Sequential Recommendation," arXiv:2512.17820, 2025.

[26] Y. Zhang, F. Feng, J. Zhang, K. Bao, Q. Wang, and X. He, "CoLLM: Integrating Collaborative Embeddings into Large Language Models for Recommendation," arXiv:2310.19488, 2023.

[27] J. Liao *et al.*, "LLaRA: Large Language-Recommendation Assistant," in *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR)*, 2024.

[28] J. Zhai *et al.*, "Actions Speak Louder than Words: Trillion-Parameter Sequential Transducers for Generative Recommendations," in *Proceedings of the 41st International Conference on Machine Learning (ICML)*, ser. PMLR, vol. 235, 2024.

[29] S. Rajput *et al.*, "Recommender Systems with Generative Retrieval," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 36, 2023.

Список литературы

[30] C. Lin, H. Lin, S. Liu, C. Ruan, L. Xu, D. Yang, C. Wang, and Y. Liu, "Dreaming User Multimodal Representation Guided by The Platonic Representation Hypothesis for Micro-Video Recommendation," arXiv:2410.03538, 2024.

[31] A. Iana, G. Glavaš, and H. Paulheim, "Peeling Back the Layers: An In-Depth Evaluation of Encoder Architectures in Neural News Recommenders," in *Proceedings of the International Workshop on News Recommendation and Analytics (INRA)*, 2024, arXiv:2410.01470.

[32] A. van den Oord, Y. Li, and O. Vinyals, "Representation Learning with Contrastive Predictive Coding," arXiv:1807.03748, 2018.

[33] O. Levy and Y. Goldberg, "Neural Word Embedding as Implicit Matrix Factorization," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 27, 2014.

[34] O. Barkan and N. Koenigstein, "Item2Vec: Neural Item Embedding for Collaborative Filtering," in *IEEE 26th International Workshop on Machine Learning for Signal Processing (MLSP)*, 2016.

[35] A. Radford *et al.*, "Learning Transferable Visual Models From Natural Language Supervision," in *Proceedings of the 38th International Conference on Machine Learning (ICML)*, ser. PMLR, vol. 139, 2021.

[36] M. Oquab *et al.*, "DINOv2: Learning Robust Visual Features without Supervision," *Transactions on Machine Learning Research (TMLR)*, 2024.

[37] K. Lenc and A. Vedaldi, "Understanding Image Representations by Measuring Their Equivariance and Equivalence," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2015.